

데이터 다루기

파이썬 데이터 구조 · pandas 연습 · 기초 통계

수업용 코드 + 개념 설명 + 실습 문제

수업 구성

1장 데이터 구조 → 2장 pandas 선택·필터링·수정 → 3장 기초 통계와 그룹별 비교

1장. 파이썬의 데이터 구조

학습 목표

- ✓ 변수, 리스트, 딕셔너리의 특징을 설명할 수 있다.
- ✓ 같은 성적 데이터를 여러 데이터 구조로 처리해 차이를 비교할 수 있다.
- ✓ 딕셔너리를 pandas DataFrame으로 변환하고 합계와 평균을 계산할 수 있다.

1. 변수를 이용한 성적 처리

핵심 개념

변수는 하나의 값을 이름을 붙여 저장하는 가장 기본적인 데이터 저장 방법입니다.

```
kor = 80
math = 40
eng = 30

total = kor + math + eng
mean = total / 3

print(total, mean)
```

코드 읽기

kor, math, eng에 점수를 저장하고, 세 값을 더해 total을 구한 뒤 3으로 나누어 평균 mean을 계산합니다.

2. 리스트를 이용한 성적 처리

```
names = ['김민준', '이지훈', '고서연', '염지민']

scores = [
    [84, 45, 36],
    [81, 76, 82],
    [58, 75, 53],
    [75, 93, 81]
]
```

```
for i in range(len(scores)):
    print(names[i], sum(scores[i]), sum(scores[i])/3)
```

생각하기

학생이 많아지면 변수를 여러 개 만드는 것보다 리스트에 묶어 저장하는 것이 편리합니다.

3. 딕셔너리를 이용한 성적 처리

```
class_dict = {
    '김민준': [84, 45, 36],
    '이지훈': [81, 76, 82],
    '고서연': [58, 75, 53],
    '염지민': [75, 93, 81]
}

for name, score in class_dict.items():
    print(name, sum(score), sum(score) / 3)
```

핵심 개념

딕셔너리는 key와 value의 쌍으로 데이터를 저장합니다. 여기서는 학생 이름이 key, 세 과목 점수 리스트가 value입니다.

4. DataFrame을 이용한 성적 처리

```
import pandas as pd

df_class = pd.DataFrame(class_dict)
df_class

print(df_class.sum())
print(df_class.mean())
```

정리

DataFrame은 행과 열로 이루어진 표 형태의 데이터 구조입니다. 여러 데이터를 비교·계산·분석할 때 편리합니다.

2장. pandas 연습 - 카페 메뉴 데이터

학습 목표

- ✓ DataFrame의 행과 열을 선택할 수 있다.
- ✓ 조건식, isin을 이용해 필요한 데이터를 필터링할 수 있다.
- ✓ 열 추가·삭제·이름 변경을 수행할 수 있다.

0. 실습 데이터 만들기

```
import pandas as pd

data = {
    '메뉴코드': ['M01', 'M02', 'M03', 'M04', 'M05'],
    '메뉴명': ['아메리카노', '카페라떼', '카푸치노', '초코라떼', '녹차라떼'],
    '카테고리': ['커피', '커피', '커피', '음료', '음료'],
    '가격': [3000, 4000, 4500, 5000, 4800],
    '판매량': [120, 95, 80, 60, 70]
}

df = pd.DataFrame(data)
df = df.set_index('메뉴코드')
df
```

1. 열(column) 선택

```
df['가격']

df[['메뉴명', '판매량']]
```

코드 해석

열 하나는 df['열이름'], 여러 열은 df[['열1', '열2']]처럼 대괄호를 한 번 더 사용합니다.

2. 행(row) 선택

```
df.loc['M01']
```

```
df.iloc[2]
```

코드 해석

loc는 인덱스 이름(label)으로, iloc는 행의 위치 번호로 선택합니다.

3. 특정 행과 열 선택

```
df.loc['M02', '가격']
```

코드 해석

행과 열을 동시에 지정하면 원하는 한 값을 선택할 수 있습니다.

4. 조건 필터링

```
df[df['가격'] >= 4000]
```

```
df[df['카테고리'] == '커피']
```

```
df[df['판매량'] >= 80]
```

코드 해석

조건식의 결과가 True인 행만 남겨 새로운 표처럼 보여줍니다.

5. 여러 조건 필터링

```
df[(df['카테고리'] == '커피') & (df['가격'] >= 4000)]
```

코드 해석

두 조건을 모두 만족하려면 &를 사용하고, 각 조건을 괄호로 묶습니다.

6. isin 사용

```
df[df['메뉴명'].isin(['아메리카노', '카푸치노'])]
```

코드 해석

isin은 여러 후보 값 중 하나에 포함되는지를 확인할 때 편리합니다.

7. 열 추가

```
df['매출'] = df['가격'] * df['판매량']  
df
```

코드 해석

새로운 열 이름에 계산식을 대입하면 열이 추가됩니다.

8. 열 삭제

```
df.drop(columns='판매량', inplace=True)  
df
```

코드 해석

inplace=True이면 변경 결과를 원래 df에 바로 반영합니다.

9. 열 이름 변경

```
df.rename(columns={'가격':'메뉴가격'})
```

코드 해석

columns에 {기존이름:새이름} 형태의 딕셔너리를 전달합니다.

실습 문제

- ① 가격이 4,500원 이상인 메뉴만 출력해 보자.
- ② 카테고리가 '음료'인 메뉴의 메뉴명과 가격만 출력해 보자.
- ③ 판매량이 70 이상이고 가격이 4,000원 이상인 메뉴를 찾아보자.
- ④ '매출' 열을 만든 뒤 매출이 가장 큰 메뉴를 예상해 보자.

3장. 데이터 기초 통계

학습 목표

- ✓ info(), shape로 데이터 구조를 확인할 수 있다.
- ✓ describe(), mean(), median(), mode()로 기초 통계를 구할 수 있다.
- ✓ value_counts(), sort_values(), groupby()를 이용해 데이터의 특징을 분석할 수 있다.

0. 데이터프레임 생성

```
import pandas as pd

data = {
    '이름': ['김하늘', '이준서', '박지민', '최서윤', '정민호'],
    '성별': ['F', 'M', 'F', 'F', 'M'],
    '키': [162, 178, 155, 160, 182],
    '몸무게': [50, 72, 47, 54, 80],
    '혈액형': ['A', 'B', 'O', 'A', 'AB']
}

df = pd.DataFrame(data)
df
```

1. 데이터 구조 확인

```
df.info()

df.shape
```

코드 해석

info()는 열 이름·결측치·자료형 등을 보여주고, shape는 (행의 수, 열의 수)를 반환합니다.

2. 기초 통계

```
df.describe()
```

```
df['키'].mean()
df['몸무게'].median()
df['혈액형'].mode()
```

코드 해석

mean은 평균, median은 중앙값, mode는 최빈값입니다. describe()는 수치형 열의 주요 통계를 한 번에 보여줍니다.

3. 범주형 데이터 분포

```
df.value_counts('혈액형')
```

코드 해석

각 혈액형이 몇 번 나타나는지 빈도를 셉니다.

4. 정렬

```
df.sort_values(by='키')

df.sort_values(by='키', ascending=False)
```

코드 해석

sort_values()는 지정한 열을 기준으로 정렬합니다. ascending=False는 내림차순입니다.

5. 그룹별 비교

```
df.groupby(by='성별')['몸무게'].mean()
```

코드 해석

성별로 데이터를 묶은 뒤 각 그룹의 몸무게 평균을 계산합니다.

기초 통계 한눈에 보기

함수	의미	예
----	----	---

info()	데이터 구조와 자료형 확인	df.info()
shape	행과 열의 개수	df.shape
describe()	기초 통계 요약	df.describe()
mean()	평균	df['키'].mean()
median()	중앙값	df['몸무게'].median()
mode()	최빈값	df['혈액형'].mode()
value_counts()	범주별 개수	df.value_counts('혈액형')
sort_values()	값을 기준으로 정렬	df.sort_values(by='키')
groupby()	그룹별 집계	df.groupby('성별')['몸무게'].mean()

마무리 문제

- ① 평균과 중앙값은 어떤 상황에서 서로 다르게 나타날 수 있을까?
- ② 혈액형처럼 숫자가 아닌 범주형 데이터의 분포를 확인할 때 어떤 함수를 사용했는가?
- ③ 키가 큰 순서대로 데이터를 정렬하려면 어떤 옵션이 필요한가?
- ④ 성별에 따른 키의 평균을 구하는 코드를 작성해 보자.

수업 정리

1장	데이터를 변수 → 리스트 → 딕셔너리 → DataFrame으로 구조화
2장	DataFrame에서 선택 → 필터링 → 추가 → 삭제 → 이름 변경
3장	데이터 구조 확인 → 기초 통계 → 분포 → 정렬 → 그룹별 비교

데이터 분석의 시작은 '데이터를 어떤 구조로 저장하고, 무엇을 확인할 것인가?'를 생각하는 것입니다.