

서울시 모기지수 공공데이터 분석과 시계열 전처리 탐구

[활동 1] 공공데이터 불러오기 및 날짜 형식(Datetime) 변환

서울시 모기지수 발생 데이터를 불러오고, 문자열 형태의 날짜 컬럼을 시계열 연산이 가능한 **datetime** 형식으로 변환합니다.

```
import pandas as pd
# 1. 한글 인코딩(cp949)을 적용하여 CSV 파일 불러오기
df = pd.read_csv("seoul_mosquito.csv", encoding="_____")

# 2. 문자열(object) 형태의 날짜 열을 판다스 날짜(datetime) 형식으로 변환
df['모기지수 발생일'] = pd._____ (df['모기지수 발생일'])
print(df.head(3)) # 열: 모기지수 발생일, 모기지수(수변부), 모기지수(주거지), 모기지수(공원)
```

[체크] 날짜를 to_datetime으로 변환하면 .dt.year, .dt.month 등 시계열 속성에 접근할 수 있습니다.

[활동 2] 전처리 전 원본 시각화와 산출 기준 변경 문제 발견

수변부 모기지수 원본 데이터를 선 그래프로 그렸을 때 발견되는 데이터의 이상 현상을 분석해 봅시다.

```
import matplotlib.pyplot as plt
import koreanize_matplotlib # 한글 깨짐 방지

plt.figure(figsize=(10, 4))
plt.plot(df['모기지수 발생일'], df['모기지수(수변부)'], linewidth=1)
plt.title('전처리 전: 수변부 모기지수 변화')
plt.xlabel('날짜'); plt.ylabel('모기지수')
plt.show()
```

문제 발견: 2020년 이전 과거 데이터는 모기지수가 최대 **1000**에 가깝게 치솟는 반면, 최근 데이터는 **0~100** 범위로 집계되어 과거와 현재의 산출 기준(Scale)이 달라 직접적인 비교가 불가능합니다.

[생각 질문] 산출 기준(단위 범위)이 다른 데이터를 전처리 없이 그대로 비교하면 어떤 오류가 발생할까요?

작성란:

[활동 3] 산출 기준 통일: 100 초과값 조정 및 과거 데이터 스케일링

모든 연도의 모기지수가 동일한 **0~100** 범위를 갖도록 연도별 조건을 지정하여 데이터를 보정합니다.

- 1단계 2020년 오류값 클리핑: 2020년 데이터 중 100을 초과한 값을 최댓값인 100으로 제한
- 2단계 2020년 4월 이전 스케일 변환: 1000점 만점으로 기록된 과거 수치를 10으로 나누어(/10) 100점 만점 기준으로 환산 (예: 800 → 80)

```
cols = ['모기지수(수변부)', '모기지수(주거지)', '모기지수(공원)']

for col in cols:
    # 1. 2020년 데이터 중 100을 초과하는 값을 100으로 변경
    조건1 = (df['모기지수 발생일'].dt.year == 2020) & (df[col] > 100)
    df.loc[조건1, col] = _____

    # 2. 2020년 4월 1일 이전 데이터를 10으로 나누어 스케일 통일
    조건2 = df['모기지수 발생일'] < '2020-04-01'
    df.loc[조건2, col] = df.loc[조건2, col] / _____
```

시계열 요약 집계와 연중 모기 활동 주기 탐구

[활동 4] strftime을 활용한 월-일(MM-DD) 시계열 문자열 추출

연도와 무관하게 1년 중 모기가 언제 가장 많이 나타나는지 분석하기 위해 연도를 제외한 월-일 열을 생성합니다.

```
# 날짜(datetime)에서 연도를 제외하고 2자리 월과 2자리 일('MM-DD') 형태로 추출
df['월-일'] = df['모기지수 발생일'].dt. _____ ('%m-%d')
print(df[['모기지수 발생일', '월-일']].head(3)) # 2026-08-25 → '08-25'
```

[활동 5] 날짜별(월-일) 다년간 평균 모기지수 집계

10여 년간 누적된 같은 날짜(예: 매년 8월 25일)의 수변부 모기지수 값들을 그룹화하여 평균을 계산합니다.

[방식 A] groupby 활용
df_day = df. _____ ('월-일', as_index=False)[
 '모기지수(수변부)'
]. _____ ()

[방식 B] pivot_table 활용
df_day = pd. _____ (
 data=df, index='월-일',
 values='모기지수(수변부)',
 aggfunc=' _____ '
).reset_index()

[함수 옵션] aggfunc에 mean(평균), max(최댓값), min(최솟값), sum(합계) 등을 지정할 수 있습니다.

[활동 6] 연중 모기지수 변화 곡선 시각화 및 계절 패턴 분석

전처리가 완료된 월-일별 평균 모기지수 그래프를 완성하고, 모기 개체수의 계절별 변화 원인을 해석해 봅시다.

```
plt.figure(figsize=(11, 4.5))
plt.plot(df_day['월-일'], df_day['모기지수(수변부)'], linewidth=1.5)
plt.title('전처리 후: 월-일별 평균 수변부 모기지수 변화', fontsize=14)
plt.xlabel('월-일'); plt.ylabel('평균 모기지수')
# x축 눈금이 너무 뽁뽁하지 않도록 10일 간격으로 표시
plt.xticks(range(0, len(df_day), _____), df_day['월-일'][:, _____], rotation=35)
plt.grid(alpha=0.3); plt.tight_layout(); plt.show()
```

질문 1. 한여름(7~8월)보다 초여름(6월)이나 초가을(9월)에 모기지수가 높게 유지되는 이유는?

질문 2. 과거 데이터의 기준(1000점)을 최근 기준(100점)으로 맞추는 전처리가 필수적인 이유는?

작성란:

작성란: