


모기 개체수 변화 데이터로 분석하기

전처리 전 그래프 → 문제 발견 → 전처리 → 계절 변화 분석

DATA STORY · 5월~10월



“5월~10월, 모기는 언제 가장 많을까?”



오늘의 분석 흐름

원본 그래프를 먼저 보고 데이터의 문제를 직접 발견합니다.

① 원본 확인

날짜형 변환
데이터 구조 확인

② 전처리 전

원본 수변부
모기지수 시각화

③ 전처리

중복 제거
범위 통일

④ 재분석

월-일 평균으로
계절 패턴 확인

핵심 질문 | “과거 모기지수가 1000 가까이 보이는 것은 정말 모기가 10배 많았다는 뜻일까?”

원본을 먼저 보고 → 문제를 발견하고 → 전처리 후 다시 비교합니다.

데이터 불러오기 + 날짜형 변환

날짜처럼 보이는 문자열을 실제 날짜 데이터로 바꿉니다.

```
import pandas as pd
```

```
df = pd.read_csv(  
    'seoul_mosquito.csv',  
    encoding='cp949'  
)  
  
df['모기지수 발생일'] = pd.to_datetime(  
    df['모기지수 발생일']  
)
```

```
df.head()
```

pd.to_datetime()

문자열을 날짜 데이터(datetime)로 변경

왜 필요할까?

뒤에서 .dt.year, .dt.strftime()처럼
연도·월·일 정보를 사용하기 위해

학생 설명 | “날짜처럼 보이는 글자를 컴퓨터가 실제 날짜로 이해하도록 바꾼다.”

전처리 전 그래프

먼저 원본 데이터를 그대로 그려 봅니다.


```
import matplotlib.pyplot as plt
import koreanize_matplotlib

plt.figure(figsize=(14, 6))

plt.plot(
    df['모기지수 발생일'],
    df['모기지수(수변부)'],
    linewidth=1
)

plt.title('전처리 전: 수변부 모기지수 변화')
plt.xlabel('날짜')
plt.ylabel('모기지수')
plt.grid(alpha=0.3)
plt.tight_layout()
plt.show()
```

BEFORE



문제 발견 | 과거와 최근 데이터의 값 범위가 서로 다릅니다.

전처리 ① 중복 제거

같은 행이 여러 번 들어 있으면 분석 결과가 왜곡될 수 있습니다.

```
print('중복 개수:', df.duplicated().sum())  
  
df = df.drop_duplicates()  
  
print('중복 제거 후 행 수:', len(df))
```

실제 데이터 확인

중복 행: 35개

drop_duplicates()

중복된 행을 제거하는 함수

전처리의 시작은 삭제가 아니라 '확인'입니다.

중복 데이터는 평균과 개수에 영향을 줄 수 있습니다.

전처리 ② 2020년의 100 초과값 수정

날짜에서 연도를 꺼낼 때 .dt.year를 사용합니다.

```
cols = [  
    '모기지수(수변부)',  
    '모기지수(주거지)',  
    '모기지수(공원)'  
]  
  
for col in cols:  
    조건 = (  
        (df['모기지수 발생일'].dt.year == 2020) &  
        (df[col] > 100)  
    )  
  
    df.loc[조건, col] = 100
```

.dt.year

날짜 데이터에서
연도만 추출

df.loc[조건, col]

조건에 해당하는 행의
특정 열 값을 수정

조건의 뜻 | “2020년이면서 모기지수가 100보다 큰 값”

전처리 ③ 값의 범위를 0~100으로 통일

2020년 4월 이전 값은 10으로 나누어 같은 기준으로 맞춥니다.

```
for col in cols:
    조건 = (
        df['모기지수 발생일']
        < '2020-04-01'
    )

    df.loc[조건, col] = (
        df.loc[조건, col] / 10
    )
```

왜 ÷ 10?

과거 0~1000 범위를
현재 0~100 범위로 통일

예시

800 → 80
350 → 35

같은 의미의 데이터는 같은 척도로 맞춰야 올바르게 비교할 수 있습니다.

같은 의미의 값은 같은 척도로 맞춰야 비교할 수 있습니다.


전처리 후 그래프

같은 날짜 축으로 다시 그려 전처리 효과를 확인합니다.

```
plt.figure(figsize=(14, 6))

plt.plot(
    df['모기지수 발생일'],
    df['모기지수(수변부)'],
    linewidth=1
)

plt.title('전처리 후: 수변부 모기지수 변화')
plt.xlabel('날짜')
plt.ylabel('모기지수')
plt.grid(alpha=0.3)
plt.tight_layout()
plt.show()
```



이제 여러 연도의 모기지수를 같은 기준에서 비교할 수 있습니다

AFTER

왜 '월-일' 열을 만들까?

이 데이터는 매년 5월부터 10월 말까지의 모기 활동을 기록합니다.

```
df['월-일'] = (  
    df['모기지수 발생일']  
        .dt.strftime('%m-%d')  
)
```

`.dt.strftime('%m-%d')`

날짜에서 연도는 빼고
월-일만 문자로 추출

2018-07-15 2019-07-15 2020-07-15 → 모두 07-15

목적 | 여러 해의 같은 날짜를 묶어 '5월~10월 중 모기가 언제 많은지' 비교하기

연도를 제거하면 여러 해의 같은 날짜를 한 그룹으로 묶을 수 있습니다.



같은 월-일끼리 평균 구하기

pivot_table로 여러 해의 같은 날짜를 하나의 평균값으로 요약합니다.

```
df_day = pd.pivot_table(  
    data=df,  
    index='월-일',  
    values='모기지수(수변부)',  
    aggfunc='mean'  
).reset_index()
```

index

같은
월-일끼리 묶기

aggfunc='mean'

묶인 값의
평균 계산

reset_index()

인덱스가 된 '월-일'을 다시 일반 열로 변경

예: 여러 해의 07-15 모기지수 → 07-15의 평균 모기지수 1개

pivot_table = 묶기 + 계산하기 + 새로운 표 만들기

최종 그래프

5월~10월의 평균적인 모기 활동 변화를 한눈에 봅니다.

```
plt.figure(figsize=(14, 6))


plt.plot(
    df_day['월-일'],
    df_day['모기지수(수변부)'],
    linewidth=1.5
)

plt.title(
    '전처리 후: 월-일별 평균 수변부 모기지수 변화'
)
plt.xlabel('월-일')
plt.ylabel('평균 모기지수')

plt.xticks(
    range(0, len(df_day), 10),
    df_day['월-일'][:10],
    rotation=35
)

plt.grid(alpha=0.3)
plt.tight_layout()
plt.show()
```

FINAL VIEW



이제 계절에 따른 모기지수의 증가·감소 패턴을 해석할 수 있습니다.



수업 정리

전처리 전·후 그래프를 비교하며 전처리의 필요성을 설명합니다.

원본 시각화

문제 발견
값의 기준이 다름

중복 제거

같은 행을
한 번만 사용

범위 통일

0~1000 →
0~100

월-일 평균

여러 해의 같은 날짜를
평균으로 요약

분석 질문 | “5월부터 10월 사이 모기는 언제 증가하고, 언제 감소하는가?”

데이터 분석의 흐름: 원본 확인 → 문제 발견 → 전처리 → 재시각화 → 의미 해석

확인 → 문제 발견 → 전처리 → 시각화 → 의미 해석

