

데이터를 그대로 믿어도 될까?

모기 개체수 변화 분석

구조 확인 → 문제 발견 → 범위 통일 → 다시 분석하기

학번		이름	
----	--	----	--

오늘의 질문 2016~2019년 수변부 모기지수가 1000 가까이 나타나는데 최근 데이터는 대부분 100 이하라면, 이 값들을 그대로 비교해도 될까?

학습 목표

- ① 데이터의 구조와 자료형을 확인하고 날짜 자료형으로 변환할 수 있다.
- ② 결측치·중복과 측정 범위의 차이를 발견하고 전처리할 수 있다.
- ③ 조건식, df.loc, for문을 이용하여 여러 데이터를 수정할 수 있다.
- ④ 월-일별 평균을 구해 모기 활동 시기의 변화를 시각화할 수 있다.

STEP 1. 데이터 불러오기와 구조 확인

```
df = pd.read_csv('.../seoul_mosquito.csv', encoding='cp949')
df.head()
df.shape
df.info()
```

실행 결과 전체 데이터는 1966행 × 4열이며, 발생일은 object, 세 모기지수 열은 float64이다.

1) df.shape의 결과 (1966, 4)는 무엇을 의미하는가?

2) df.info()를 사용하면 어떤 정보를 확인할 수 있는가?

STEP 2. 문자열 날짜를 날짜 데이터로 변경하기

```
df['모기지수 발생일'] = pd.to_datetime(df['모기지수 발생일'])  
df.info()
```

변화 '모기지수 발생일'의 자료형이 object → datetime64[ns]로 변경된다.

3) pd.to_datetime()을 사용하는 이유를 설명해 보자.

4) 날짜 자료형으로 바꾸면 .dt.year와 같은 기능을 사용할 수 있다. 이것이 이후 전처리에 왜 유용할까?

STEP 3. 전처리 전 그래프에서 문제 발견하기

```
plt.figure(figsize=(10,5))  
plt.plot(df['모기지수 발생일'], df['모기지수(수변부)'], linewidth=1)  
plt.title('전처리 전: 수변부 모기지수 변화', fontsize=18)  
plt.xlabel('날짜')  
plt.ylabel('모기지수(수변부)')  
plt.grid(alpha=0.3)  
plt.tight_layout()  
plt.show()
```

관찰 포인트 2016~2019년은 1000 가까운 값이 보이지만 최근 데이터는 대부분 100 이하이다. 실제 변화인지 측정 기준의 차이인지 확인해야 한다.

5) 전처리 전 그래프에서 가장 먼저 의심되는 문제를 적어 보자.

6) 수변부 데이터를 먼저 살펴보는 이유는 무엇일까? 자료의 설명을 바탕으로 적어 보자.

STEP 4. 결측치와 중복 데이터 확인하기

```
print(df.isnull().sum())
print('중복 제거 전 원래 행 개수:', len(df))
print('중복 개수:', df.duplicated().sum())
df = df.drop_duplicates()
print('중복 제거 후 행 수:', len(df))
```

실행 결과 결측치는 0개 / 중복은 35개 / 1966행 → 중복 제거 후 1931행

7) 1966 - 35를 계산하여 중복 제거 후 행 수를 확인해 보자.

8) 중복 데이터를 제거하지 않고 평균이나 합계를 계산하면 어떤 문제가 생길 수 있을까?

STEP 5. 2020년 4월 이전 데이터의 범위 통일하기

처리 기준 2020년 4월 1일 이전 데이터는 과거 1000 단위 기준이므로 현재 0~100 범위와 비교할 수 있도록 10으로 나눈다.

```
조건 = (df['모기지수 발생일'] < '2020-04-01') & (df['모기지수(수변부)'] > 100)
print(df[조건].index)
```

확인 결과 조건에 해당하는 수변부 데이터의 인덱스는 630개가 확인된다.

9) 위 조건식이 선택하는 데이터를 우리말로 풀어 써 보자.

10) 조건을 만족하는 첫 번째 인덱스는 1249이다. 이 인덱스를 확인하는 이유는 무엇일까?

STEP 6. 한 개의 값을 먼저 수정해 확인하기

```
샘플_인덱스 = df[조건].index[0]
display(df.loc[샘플_인덱스, ['모기지수 발생일', '모기지수(수변부)']])
df.loc[샘플_인덱스, '모기지수(수변부)'] = df.loc[샘플_인덱스, '모기지수(수변부)'] / 10
```

수정 예 2019-10-26의 수변부 모기지수 179.9 → 17.99

11) 800, 560, 245.5를 각각 같은 기준으로 수정하면 얼마가 되는가?

12) 전체 데이터를 한 번에 수정하기 전에 한 행을 먼저 수정해 확인하는 이유는 무엇일까?

STEP 7. for문으로 세 지역 유형을 한 번에 처리하기

```
cols = ['모기지수(수변부)', '모기지수(주거지)', '모기지수(공원)']
for col in cols:
    조건 = df['모기지수 발생일'] < '2020-04-01'
    df.loc[조건, col] = df.loc[조건, col] / 10
```

13) for col in cols:를 사용하면 어떤 장점이 있는가?

14) 이 코드에서는 2020-04-01 이전의 세 모기지수 열을 모두 어떻게 변경하는가?

STEP 8. 2020년의 100 초과값을 100으로 수정하기

```
조건 = (df['모기지수 발생일'].dt.year == 2020) & (df['모기지수(수변부)'] > 100)
print(df[조건].index)
```

확인 결과 조건에 해당하는 수변부 데이터는 128개이며, 예: 2020-10-05의 102.1 → 100.0

15) 이 조건식에서 .dt.year == 2020과 > 100은 각각 무엇을 의미하는가?

STEP 9. 2020년 초과값을 여러 열에서 한 번에 수정하기

```
cols = ['모기지수(수변부)', '모기지수(주거지)', '모기지수(공원)']
for col in cols:
    조건 = (df['모기지수 발생일'].dt.year == 2020) & (df[col] > 100)
    df.loc[조건, col] = 100
```

16) df.loc[조건, col] = 100은 어떤 행과 열의 값을 수정하는가?

17) cols 리스트에서 '모기지수(주거지)'를 빼면 어떤 결과가 생기는가?

STEP 10. 전처리 후 그래프 다시 그리기

```
plt.plot(df['모기지수 발생일'], df['모기지수(수변부)'], linewidth=1)
plt.title('전처리 후: 수변부 모기지수 변화', fontsize=18)
plt.xlabel('날짜')
plt.ylabel('모기지수')
plt.grid(alpha=0.3)
plt.show()
```

그래프 변화 과거 데이터와 최근 데이터가 같은 0~100 범위에서 비교된다.

18) 전처리 전 그래프와 비교했을 때 가장 크게 달라진 점을 적어 보자.

19) 서로 다른 측정 범위의 데이터를 그대로 비교하면 왜 위험한가?

STEP 11. 연도를 제외하고 월-일만 추출하기

```
df['월-일'] = df['모기지수 발생일'].dt.strftime('%m-%d')
df['월-일']
```

20) strftime('%m-%d')에서 %m과 %d는 각각 무엇을 의미하는가?

21) 2026-08-25는 '월-일' 열에 어떤 문자열로 저장되는가?

STEP 12. 같은 월-일끼리 평균 구하기

```
df_day = df.groupby('월-일')['모기지수(수변부)'].mean().reset_index()  
df_day
```

분석 아이디어 연도를 제외하고 같은 월.일의 모기지수를 평균내면 5월부터 10월까지 계절에 따른 모기 활동 변화를 볼 수 있다.

22) groupby('월-일')은 데이터를 어떤 기준으로 묶는가?

23) mean()을 사용하는 이유는 무엇일까?

STEP 13. 월-일별 평균 모기지수 시각화

```
plt.figure(figsize=(10,5))  
plt.plot(df_day['월-일'], df_day['모기지수(수변부)'], linewidth=1.5)  
plt.title('전처리 후: 월-일별 평균 수변부 모기지수 변화', fontsize=18)  
plt.xlabel('월-일')  
plt.ylabel('평균 모기지수')  
plt.xticks(range(0, len(df_day), 10), df_day['월-일'][:10], rotation=35)  
plt.grid(alpha=0.3)  
plt.tight_layout()  
plt.show()
```

그래프 읽기 5월 초에는 비교적 낮고, 6~7월에 높은 수준으로 올라가며, 8~9월에도 높게 유지되다가 10월에 다시 낮아지는 흐름을 볼 수 있다.

24) 최종 그래프에서 모기지수가 가장 높은 시기를 대략적으로 적어 보자.

25) x축 눈금을 10일 간격으로 표시한 이유는 무엇일까?
